

基于改进 Elman 网络的动态系统测量数据检验方法

司风琪 洪 军 徐治皋

(东南大学动力工程系, 南京 210096)

摘要: 为了提高动态系统测量数据的准确性, 提出了基于改进 Elman 网络的动态系统测量数据检验方法. 采用一步前预测方法构造网络的训练样本, 用带自适应学习率的动态 BP 算法进行网络的训练, 通过训练后的网络对各测量参数进行估计, 实现测量数据的在线检验. 对某电厂 CCS 系统进行了仿真试验, 结果表明该方法可避免形成简单的一一对应映射, 能正确获取系统动态特性, 具有较强的降噪能力, 能够正确辨识出测量数据中存在的不良值, 提高了系统监测的可靠性和健壮性.

关键词: Elman 网络; 动态系统; 数据检验; 电站

中图分类号: TK39 **文献标识码:** A **文章编号:** 1001-0505(2005)01-0050-05

Dynamic system data validation method based on the improved Elman network

Si Fengqi Hong Jun Xu Zhigao

(Department of Power Engineering, Southeast University, Nanjing 210096, China)

Abstract: A novel data validation method based on the modified Elman network is presented to detect gross errors in measured data of dynamic system. The structure of the dynamic recurrent network is given, the dynamic back propagation (BP) learning method is presented and the one-step-ahead method is adopted for creating training set. The simulation results of a coordinate control system (CCS) in power plant indicate that the dynamics of the system is achieved and the predicted value follows the real trend well. By the right detection of the invalid parts existing in the sampling data, the effectiveness and robustness of the whole system is improved.

Key words: Elman network; dynamic system; data validation; power plant

随着先进控制技术、计算机网络技术及其他信息技术的广泛应用, 电站自动化水平不断提高. 电站性能在线监测、设备状态检测以及机组运行优化等系统可从现场采集的数据也越来越多, 但是这些测量数据中可能包含一些不良数据, 从而大大影响计算结果的准确性, 因此有必要对测量数据中的不良值进行检验.

有关研究人员已经发展了多种数据检验的算法, 如基于硬件冗余的互判法, 基于采样数据的时间序列关系的 AR, ARMA 以及 Kalman 等时间序列预测模型, 以及基于机理模型采用解析冗余技术的参数预测方法等^[1~3]. 这些方法建立描述数据或系统的模型, 对数据进行估计, 再与测量值进行比较, 以检验数据的正确性. 但是电站热力系统比较复杂, 一

些热力过程表现为一种典型的非线性动态过程, 如果建立过程机理模型, 需要作一些近似和假设, 而且模型比较复杂. 而神经网络作为一种先进的建模方法, 在处理非线性、不确定因素较强的问题上得到了广泛应用. 本文提出了基于改进的 Elman 网络的动态系统测量数据检验方法, 并进行了仿真试验, 结果表明了该算法的正确性.

1 动态系统神经网络建模

从网络结构看, 常见的动态系统神经网络大致可以分为两大类, 即前馈神经网络和反馈神经网络^[4].

1.1 前馈结构

如图 1 所示, 主要的网络结构是静态前馈网络, 通过延时单元将系统一定时间窗内的测量数据作为网络的输入, 其实现的映射关系为

收稿日期: 2004-12-06.

作者简介: 司风琪(1973—), 男, 博士, 副教授, fqi@seu.edu.cn.

$$y_{net}(k) = F(u(k), u(k-1), \dots, u(k-m_u), y(k-1), y(k-2), \dots, y(k-n_y)) \quad (1)$$

式中, m_u, n_y 分别为系统输入、输出参数的时间窗长度; $y_{net}(k)$ 为网络输出。




图 1 前馈网络结构示意图

1.2 反馈结构

在网络的内部节点间增加反馈连接,根据节点的连接情况又分为 2 类,即外反馈网络和内反馈网络,如图 2 所示。




图 2 反馈网络结构示意图

1.2.1 外反馈网络

当前时刻前一定时间窗内网络的输出作为网络输入的一部分,如图 2(a) 所示,网络映射关系为

$$y_{net}(k) = G(u(k), u(k-1), \dots, u(k-m_u), y_{net}(k-1), y_{net}(k-2), \dots, y_{net}(k-n_y)) \quad (2)$$

1.2.2 内反馈网络

将网络隐层前一时刻的输出与测量数据一起作为网络的输入,如图 2(b) 所示,网络映射关系为

$$y_{net}(k) = H(u(k), u(k-1), \dots, u(2), u(1), y(k-1), y(k-2), \dots, y(2), y(1)) \quad (3)$$

研究表明^[5],进行动态系统建模与辨识时反馈网络的性能优于前馈网络,而内反馈比外反馈又有更多的优势。

2 改进的 Elman 网络

Elman 网络是一种具有典型内反馈结构的动态

递归网络^[6],当 Elman 网络用于辨识单输入单输出对象时,只需要一个输入单元、一个输出单元和 $n+1$ 个隐层单元,比相应的静态网络结构简单。但是常规 Elman 网络采用标准 BP 学习算法训练时仅能辨识一阶线性动态系统^[5]。

2.1 改进的 Elman 网络结构

针对 Elman 网络的一些不足,许多学者对其训练方法与网络结构进行了研究,提出了比较多的网络训练方法,如 BPTT(backpropagation through time) 方法、RTBP(real-time recurrent backpropagation) 方法以及遗传算法^[7] 等。在网络结构改进方面,文献^[8] 在 Elman 网络的输入输出之间增加了直接连接的权值。本文应用的是一种改进的 Elman 网络,通过结构单元上增加了一个固定增益为 1 的自反馈连接,能够有效地辨识高阶的动态系统,其网络结构如图 3 所示。图中, $u(k)$ 为网络的外部输入, $y_{net}(k)$ 为网络输出, $x(k)$ 为隐层输出, $x_c(k)$ 为结构单元输出。由于在结构单元上增加了一个固定增益为 1 的自反馈连接,使结构单元在 k 时刻的输出等于隐层在 $k-1$ 时刻的输出加上结构单元在 $k-1$ 时刻输出值的 α 倍。




图 3 改进 Elman 网络示意图

以单输入、单输出为例,假设隐层节点数目为 n ,输入单元到隐层单元的连接权值为 $W^u(n \times 1)$,结构单元到隐层单元的连接权值为 $W^x(n \times n)$,隐层单元到输出单元的连接权值为 $W^y(1 \times n)$,整个网络结构可以用下式来描述:

隐层第 i 个节点输入

$$v_i(k) = \sum_{j=1}^n W_{i,j}^x(k-1) x_j^c(k) + W_{i,1}^u(k-1) u(k) \quad (4)$$

隐层第 i 个节点输出

$$x_i(k) = f(v_i(k)) \quad (5)$$

结构单元的输出

$$x_i^c(k) = x_i(k-1) + x_i^c(k-1) \quad (6)$$

网络的输出

$$y_{\text{net}}(k) = g \left(\sum_i^n W_{1,i}^y(k-1) x_i(k) \right) \quad (7)$$

式中, $f(\cdot)$ 为隐层单元的激励函数(通常取 Sigmoid 函数); $g(\cdot)$ 为输出单元的激励函数(通常取线性函数)。

2.2 改进的 Elman 网络学习算法

采用带自适应学习率的动态 BP 算法对改进的 Elman 网络进行训练. 具体算法为

$$W_{1j}^y(k) = (y_d(k) - y_{\text{net}}(k)) g_{x_j} x_j(k) \quad (8)$$

$$j = 1, 2, \dots, n$$

$$W_{j1}^u(k) = (y_d(k) - y_{\text{net}}(k)) g_{x_j} W_{1j}^y f_{v_j} u(k-1) \quad (9)$$

$$j = 1, 2, \dots, n$$

$$W_{j1}^x = (y_d(k) - y_{\text{net}}(k)) g_{x_j} W_{1j}^y \frac{\partial x_j(k)}{\partial W_{j1}^x} \quad (10)$$

$$j = 1, 2, \dots, n; 1 = 1, 2, \dots, n$$

式中, y_d 为网络训练目标值; g_{x_j}, f_{v_j} 分别为函数

$$g(\cdot), f(\cdot) \text{ 的一阶导数; } \frac{\partial x_j(k)}{\partial W_{j1}^x} = f_{v_j} x_j(k-1) + \frac{\partial x_j(k-1)}{\partial W_{j1}^x}.$$

3 基于改进的 Elman 网络的测量数据检验

将改进的 Elman 网络应用到动态系统测量数据检验问题时,其实质是通过样本的训练,使训练后网络可以获取输入输出参数之间的动态特性,包括参数间的互相关特性和参数自身的自相关特性. 与其他应用不同的是网络输入输出参数,在数据检验问题中,网络的输入通常为系统参数的实际测量矢量 $x(k)$, 网络的输出为对应测量矢量的估计值 $x_{\text{net}}(k)$, 此时对应的系统框图如图 4 所示.




图 4 常规方法进行数据检验

网络的输入层与输出层节点个数相等,其映射关系为

$$x_{\text{net}}(k) = f(x(k), x(k-1), \dots, x(2), x(1)) \quad (11)$$

式中, $x(k), x(k-1), \dots, x(2), x(1)$ 分别为当前时刻及以前的参数测量矢量; $x_{\text{net}}(k)$ 为当前时刻网络

的估计值.

网络的训练过程是系统辨识过程,通过训练可以找到一个合适的映射以满足网络输入输出的对应关系,这种对应关系能够正确反映系统的特性. 但是,对图 4 所示的系统训练时很容易形成简单的一一对应关系,这样就失去了数据估计的作用.

采用 Elman 网络建立动态系统模型时,只要测量周期满足一定的条件,可以认为系统当前的输出仅取决于过去的测量数据矢量,这样可以采用一步前预测方法进行网络建模与测量数据估计,如图 5 所示,网络的映射关系为

$$x_{\text{net}}(k) = f(x(k-1), x(k-2), \dots, x(2), x(1)) \quad (12)$$

通常可以认为测量数据中的噪声互不相关,噪声数据之间不存在简单的映射关系,这样网络训练时只会辨识出测量数据之间的固有联系,从而能够有效地滤去噪声,使得网络输出为当前时刻各参数的优化估计值.



图 5 采用一步前预测进行数据检验

4 算 例

协调控制是大型火电机组最主要的控制回路之一,保证其测量参数的准确性对机组的安全经济运行具有十分重要的意义. 尽管现场对于其中一些重要参数采用了硬件冗余的方法,但是需要增加额外的投资,因此有必要研究该系统测量数据检验方法,文献[9]提出了基于机理模型的方法,将故障参数扩展到状态向量中,采用 Kalman 滤波方法进行检测,但是必须建立准确的系统模型,而协调系统本身是一个比较典型的强耦合系统,具有复杂的动态特性,目前虽然提出了多种辨识模型的方法,但是得到的大都为近似模型,这就影响了一些对模型要求高的方法的应用效果.

本文以某 125 MW 机组的协调控制系统为例[9],考察本文算法的有效性. 对象模型为

$$\begin{bmatrix} N_E \\ P_T \end{bmatrix} = \begin{bmatrix} W_{NT}(s) & W_{NB}(s) \\ W_{PT}(s) & W_{PB}(s) \end{bmatrix} \begin{bmatrix} u_T \\ u_B \end{bmatrix} \quad (13)$$

式中, N_E, P_T 为机组实发功率和主蒸汽压力; u_T, u_B 为汽轮机调门指令和燃烧率指令; $W_{NT}(s)$ 和 $W_{PT}(s)$ 分别为输入 u_T 、输出 N_E 和 P_T 的传递函数;

$W_{NB}(s)$ 和 $W_{PB}(s)$ 分别为输入 u_B 、输出 N_E 和 P_T 的传递函数. 机组采用炉跟机方式运行,系统动态特性为^[9]

$$\left. \begin{aligned} W_{NT}(s) &= \frac{68.81s}{(1+12s)(1+82s)} \\ W_{PT}(s) &= -2.194 \left[\frac{0.064}{1+3s} + \frac{0.936}{1+124s} \right] \\ W_{NB}(s) &= \frac{1}{(1+83s)^2} \\ W_{PB}(s) &= \frac{2.194}{(1+80s)^2} \end{aligned} \right\} \quad (14)$$

4.1 网络训练与测试

采用 Matlab^[10]对研究对象进行仿真,在 u_T 中加入范围为[0.2,1.0]随机阶跃扰动,采样间隔 1 s,仿真时间 1 000 s,共采集 1 000 组仿真数据.

以 N_E , P_T , u_T 和 u_B 4 个变量的测量参数为检测对象,网络隐层节点数取 8,从而形成 4-8-4 的网络结构.将测量数据进行标准化处理,根据一步前预测的要求,以前一时刻测量数据作为网络输入,当前时刻测量数据作为网络输出的目标值,将前 400 个仿真数据作为网络训练样本,后 600 个作为网络测试样本.

4.1.1 不考虑测量数据中的噪音

网络初始学习率取为 0.15,反馈连接 $\beta = 0.4$,动量因子为 0.1.经过 15 000 步的训练,网络误差和为 3.0×10^{-3} .以主汽压力为例,图 6 显示了网络训练与测试结果.




图 6 网络输入无噪音时改进的 Elman 网络训练及测试结果示意图

4.1.2 考虑测量数据中的噪音

在测量数据中分别加入方差为 0.01 的随机白噪声,直接用这些带有噪音的数据构成网络训练样本,经过 17 000 步的训练后,网络误差平方和为 1.65,继续训练,则会引起较大的波动,表明网络正

试图对噪音进行辨识,此时便结束网络训练.仍然以主汽压力为例,图 7 显示网络训练与测试结果,可见网络除了正确地获取了系统动态特性外还有很好的降噪功能.





图 7 网络输入中含有噪音时改进的 Elman 网络训练及测试结果示意图

4.2 不良数据检验


以主汽压力为例,自第 500 个数据起,迭加下式定斜率故障数据:

$$f(k) = \begin{cases} 0.0 & k < 600 \\ 0.001(k - 600) & k \geq 600 \end{cases} \quad (15)$$

如图 8(a)所示,故障数据的加入,使 P_T 的测量数据自第 500 个数据起逐渐偏离其真实值,而采用本文



(a) 网络估计结果



(b) 数据检验残差

图 8 P_T 发生定斜率漂移时数据检验结果示意图

算法则可以得到 P_T 的正确估计值. 图 8(b) 所示为各参数测量值与估计值之间的残差, 通过其可以比较容易地检测并定位故障参数, 从而提高系统的可靠性, 保证整个系统的安全运行.

5 结 语

针对改进 Elman 网络的特点, 本文提出了动态系统测量数据不良值检验的一种新方法. 在构造网络训练样本时, 采用一步前预测方法, 可以避免网络训练时形成简单的一一对应映射. 通过某电厂 CCS 系统的仿真实例表明本文方法能正确获取系统动态特性, 具有较强的降噪能力, 在测量数据异常时也可以正确估计出系统各参数的值, 有较好的应有前景.

参考文献 (References)

- [1] 司风琪. 电站性能在线监测中的数据检验和热力系统模型研究 [D]. 南京: 东南大学动力工程系, 2001.
- [2] 李 明, 徐向东. 传感器故障检测的 Powell 神经网络方法 [J]. 热能动力工程, 2002, 17(1): 73 - 75.
Li Ming, Xu Xiangdong. Sensor failure detection based on a Powell neural network method [J]. Journal of Engineering for Thermal Energy and Power, 2002, 17(1): 73 - 75. (in Chinese)
- [3] 黄孝彬, 牛玉广, 刘吉臻, 等. 基于模糊动态模型的传感器故障诊断方法 [J]. 中国电机工程学报, 2003, 23(3): 183 - 187.
Huang Xiaobin, Niu Yuguang, Liu Jizhen, et al. Fault diagnosis for sensors based on fuzzy dynamical model [J]. Proceedings of the CSEE, 2003, 23(3): 183 - 187. (in Chinese)
- [4] 焦李成. 神经网络的应用与实现 [M]. 西安: 西安电子科技大学出版社, 1993. 26 - 45.
- [5] Qin Sir-zhao, Su Hong-te, McAvoy Thomas J. Comparison of four neural net learning methods for dynamic system identification [J]. IEEE Transactions on Neural Networks, 1992, 3(1): 122 - 130.
- [6] Elman J L. Finding structure in time [J]. Cognitive Science, 1990, 14: 179 - 211.
- [7] Pham D T, Karaboga D. Training Elman and Jordan networks for system identification using genetic algorithms [J]. Artificial Intelligence in Engineering, 1999, 13(2): 107 - 117.
- [8] Peter J M, Barry L K. Parallel training of simple recurrent neural networks [A]. In: International Symposium on Speech, Image Processing and Neural Networks [C]. New York, 1994. 167 - 170.
- [9] 丁艳军. 电站热工过程故障诊断方法研究 [D]. 南京: 东南大学动力工程系, 2000.
- [10] 王沫然. Simulink 4 建模及动态仿真 [M]. 北京: 电子工业出版社, 2002. 25 - 30.